

Relatório AD1 - Fernando Paladini

Avaliação a Distância 1 - Tópicos Especiais

Aluno: Fernando Paladini

Repositório

Link do repositório pessoal no GitHub: <https://github.com/paladini/sri>

Pasta de saída com o relatório e artefatos gerados: [output/](#)

Execução dos notebooks

Antes da sequência principal da avaliação, foi criado o notebook `0_0_PrepararDocumentosCSV_trainjson_v1.ipynb`. Esse notebook adapta o dataset escolhido para o formato de entrada esperado pelos notebooks disponibilizados pelo professor, gerando o arquivo `data/documentos.csv` com as colunas `id` e `documento`.

Os notebooks disponibilizados pelo professor foram executados em 24/05/2026, a partir do ambiente virtual `.venv`, na ordem solicitada:

1. `1_1_Segmentacao_Limpeza_v1.ipynb`
2. `1_2_GerarPOS_v1.ipynb`
3. `1_3_NER_spacy_v1.ipynb`
4. `2_1_AnaliseDados_v1.ipynb`

Os arquivos de dados gerados pelos notebooks ficam na pasta `data/`. Os relatórios, imagens e exports ficam centralizados na pasta [output/](#). Os principais arquivos adicionados ao repositório foram:

Arquivo	Descrição
<code>0_0_PrepararDocumentosCSV_trainjson_v1.ipynb</code>	Notebook criado para adaptar o dataset escolhido ao formato esperado pela sequência principal.
<code>data/dataset.csv</code>	Documentos limpos e segmentados em sentenças.
<code>data/datasetpos.csv</code>	Saída de POS Tagging gerada com spaCy.
<code>data/datasetner.csv</code>	Saída de NER gerada com spaCy.
<code>output/relatorio_ad1.md</code>	Relatório principal da Avaliação à Distância 1.
<code>output/relatorio_ad1_export/2_1_AnaliseDados_v1.md</code>	Export completo do notebook de análise com tabelas e gráficos.
<code>output/relatorio_ad1_export/2_1_AnaliseDados_v1_files/</code>	Imagens PNG geradas pelo notebook de análise.

Essa organização mantém a raiz do repositório semelhante ao SRI original, com notebooks na raiz e a pasta `data/` com os arquivos processados, enquanto os materiais finais de entrega ficam agrupados em `output/`.

Descrição do texto utilizado

O corpus utilizado foi o dataset de notícias do GovBR disponível no Hugging Face: [divergente/noticias-govbr-ptbr-1](#).

Como os notebooks `1_1` até `2_1`, disponibilizados pelo professor, esperam um arquivo `data/documentos.csv` com as colunas `id` e `documento`, foi criado o notebook `0_0_PrepararDocumentosCSV_trainjson_v1.ipynb` para adaptar o dataset escolhido a esse formato. O script lê o arquivo de entrada do dataset (`train.json`), extrai o campo textual utilizado na análise, normaliza os registros e gera o CSV consumido pelas etapas seguintes.

Após a adaptação, o corpus utilizado no processamento ficou preparado no arquivo `data/documentos.csv`. Ele possui 500 documentos curtos, armazenados nas colunas `id` e `documento`. Cada documento corresponde a um título textual em português extraído de notícias do portal GovBR. A base utilizada contém principalmente títulos relacionados a governo, controle público, Polícia Federal, CGU, operações, investigações, Covid-19 e ações institucionais.

Depois do pré-processamento, o arquivo `data/dataset.csv` manteve 500 documentos e 567 sentenças. O processamento linguístico foi feito com spaCy, usando o modelo `pt_core_news_lg`; a análise também utiliza o tokenizador BERT `neuralmind/bert-base-portuguese-cased`.

Resumo geral da base:

Métrica	Valor
Documentos	500
Sentenças	567
Entidades nomeadas reconhecidas	1032
Classes NER encontradas	LOC, MISC, ORG, PER

Exemplo de POS Tagging

Sentença utilizada:

Brasil inicia construção do 5 Plano de Ação Nacional de Governo Aberto

Token	POS	Lema
Brasil	PROPN	Brasil
inicia	VERB	iniciar
construção	NOUN	construção
do	ADP	de o
5	PROPN	5
Plano	PROPN	Plano
de	ADP	de
Ação	PROPN	Ação
Nacional	PROPN	Nacional
de	ADP	de
Governo	PROPN	Governo
Aberto	PROPN	Aberto

Verbo identificado na sentença: `inicia` .

Exemplo de NER

Sentença utilizada:

Brasil inicia construção do 5 Plano de Ação Nacional de Governo Aberto

Entidade	Classe	Início	Fim
Brasil	LOC	0	6
5 Plano de Ação Nacional de Governo Aberto	MISC	28	70

Tabelas da análise de dados

Distribuição de POS no corpus

POS	Ocorrências
PROPN	1612
NOUN	1382
ADP	1353
VERB	725
ADJ	336
NUM	178
PUNCT	136
CCONJ	132
DET	112
ADV	62
SCONJ	55
AUX	19
PRON	16
SYM	5

Distribuição de NER no corpus

Classe	Ocorrências	Exemplo mais frequente
LOC	492	Polícia Federal
ORG	378	PF
MISC	151	BPFRON
PER	11	LENI NCIA

Estatísticas por documento

Estatística	Sentenças	Palavras	Tokens BERT	Palavras sem stopwords	Verbos	Substantivos	Entidades
Média	1.13	12.25	17.19	8.52	1.45	2.76	2.06
Desvio padrão	0.45	3.61	5.25	2.40	0.71	1.40	0.90
Mínimo	1.00	3.00	3.00	2.00	0.00	0.00	0.00
Mediana	1.00	12.00	17.00	8.00	1.00	3.00	2.00
Máximo	4.00	27.00	40.00	19.00	4.00	7.00	6.00

Estatísticas por sentença

Estatística	Palavras	Tokens BERT	Palavras sem stopwords	Verbos	Substantivos	Entidades
Média	10.80	15.16	7.51	1.28	2.44	1.82
Desvio padrão	4.53	6.28	2.96	0.77	1.50	0.89
Mínimo	1.00	1.00	0.00	0.00	0.00	0.00
Mediana	11.00	15.00	8.00	1.00	2.00	2.00
Máximo	23.00	38.00	17.00	4.00	7.00	5.00

Estatísticas por janela


Estatística	Palavras	Tokens BERT	Palavras janela 3	Palavras janela 5	Tokens janela 3	Tokens janela 5
Média	10.80	15.16	12.36	12.52	17.41	17.64
Desvio padrão	4.53	6.28	3.92	3.83	5.72	5.60
Mínimo	1.00	1.00	2.00	3.00	2.00	3.00
Mediana	11.00	15.00	12.00	12.00	17.00	17.00
Máximo	23.00	38.00	27.00	27.00	40.00	40.00

As tabelas completas exportadas diretamente do notebook estão em [relatorio_ad1_export/2_1_AnaliseDados_v1.md](#).

Gráficos gerados pelo notebook de análise


Todos os gráficos abaixo foram gerados pelo notebook `2_1_AnaliseDados_v1.ipynb`, a partir dos arquivos `data/dataset.csv`, `data/datasetpos.csv` e `data/datasetner.csv`.

Por documento




Boxplot das estatísticas gerais por documento

Este boxplot resume as medidas gerais por documento, como quantidade de sentenças, palavras, tokens BERT, palavras sem stopwords, verbos, substantivos e entidades. A maior parte dos documentos é curta, com mediana de 12 palavras, 17 tokens BERT e 1 sentença por documento.




Boxplot de POS Tagging por documento

O gráfico compara a distribuição das classes gramaticais por documento. As classes mais presentes são **PROPN** , **NOUN** e **ADP** , o que faz sentido para títulos de notícias, pois eles concentram nomes próprios, substantivos e preposições.




Distribuição de POS Tagging por documento

Este gráfico mostra a frequência total das classes POS no corpus. A predominância de **PROPN** , **NOUN** , **ADP** e **VERB** é coerente com um corpus formado por títulos jornalísticos institucionais.



Boxplot de NER por documento

O boxplot de NER apresenta a quantidade de entidades por classe em cada documento. As classes **LOC** e **ORG** aparecem com mais frequência, resultado esperado para notícias do GovBR que citam órgãos, localidades, operações e instituições.




Distribuição de NER por documento

Este gráfico sintetiza a distribuição das entidades nomeadas. A classe **LOC** foi a mais frequente, seguida de **ORG**, **MISC** e **PER**; isso mostra que o corpus contém mais referências geográficas e institucionais do


que nomes de pessoas.

Por sentença




Boxplot das estatísticas gerais por sentença

O gráfico apresenta as estatísticas no nível das sentenças. Como os documentos são títulos curtos, as sentenças também têm distribuição concentrada: média de 10,80 palavras e 15,16 tokens BERT por sentença.



Boxplot de POS Tagging por sentença

Este boxplot mostra como as classes POS se distribuem por sentença. **PROPN**, **NOUN** e **ADP** continuam concentrando os maiores valores, confirmando o padrão observado na análise por documento.



Distribuição de POS Tagging por sentença

O gráfico agrega as ocorrências de POS nas sentenças. Ele reforça que a estrutura linguística dos títulos é formada principalmente por nomes próprios, substantivos, preposições e verbos.




Gráfico POS por sentença - ADP

Este gráfico detalha a ocorrência de **ADP** por sentença. A frequência de preposições é compatível com títulos que conectam órgãos, ações, locais e complementos, como em expressões do tipo “de”, “em” e “para”.




Gráfico POS por sentença - PROPN

O gráfico de **PROPN** destaca a presença de nomes próprios nas sentenças. Esse resultado é esperado em notícias governamentais, que mencionam instituições, programas, operações e localidades específicas.




Gráfico POS por sentença - NOUN

A distribuição de **NOUN** mostra a frequência de substantivos comuns. Essa classe é importante no corpus porque os títulos descrevem ações, objetos de investigação, políticas públicas e temas administrativos.




Gráfico POS por sentença - VERB

O gráfico de **VERB** indica que a maioria das sentenças contém poucos verbos, geralmente um ou dois. Isso é coerente com títulos jornalísticos, que costumam expressar uma ação principal de forma direta.




Gráfico POS por sentença - ADJ

O gráfico de **ADJ** mostra menor frequência de adjetivos em comparação com substantivos e nomes próprios. O resultado combina com o estilo informativo dos títulos, que tende a priorizar fatos e entidades.






Gráfico POS por sentença - NUM

O gráfico de **NUM** evidencia ocorrências numéricas em parte das sentenças. Isso aparece em títulos com datas, valores, números de operações, planos, edições ou quantidades.



Boxplot de NER por sentença

O boxplot de NER por sentença mostra que cada sentença normalmente possui poucas entidades, com mediana de 2 entidades. Isso é compatível com sentenças curtas oriundas de títulos.



Distribuição de NER por sentença

Este gráfico mostra a frequência das classes NER nas sentenças. **LOC** e **ORG** seguem como as classes mais relevantes, indicando presença forte de lugares e organizações.




Gráfico NER por sentença - LOC

O gráfico de **LOC** detalha as entidades de localização por sentença. A concentração dessa classe é coerente com notícias que citam estados, cidades, países, órgãos tratados pelo modelo como localização e áreas de atuação.




Gráfico NER por sentença - ORG

O gráfico de **ORG** mostra a distribuição de organizações por sentença. A presença de órgãos como PF e CGU explica a frequência dessa classe no corpus.





Gráfico NER por sentença - MISC


O gráfico de **MISC** reúne entidades diversas que não se encaixam diretamente como pessoa, organização ou localização. Essa classe aparece em nomes de operações, programas e expressões institucionais.

Distribuições por documento




Quantidade de documentos por quantidade de sentenças

Este gráfico confirma que a maioria dos documentos possui apenas uma sentença. Isso faz sentido porque o corpus processado utiliza títulos de notícias, que normalmente são textos curtos.




Quantidade de documentos por quantidade de palavras

O gráfico mostra a distribuição dos documentos pela quantidade de palavras. A maior concentração fica em documentos curtos, com mediana de 12 palavras.




Quantidade de documentos por quantidade de tokens

Este gráfico mostra a distribuição por tokens BERT. A mediana de 17 tokens e o máximo de 40 no dataset processado indicam que os documentos estão muito abaixo do limite de 512 tokens.




Quantidade de documentos por quantidade de palavras sem stopwords

O gráfico mostra a quantidade de palavras restantes após a remoção de stopwords. A redução em relação ao total de palavras é esperada, pois títulos em português contêm preposições e artigos frequentes.




Quantidade de documentos por quantidade de locuções verbais

Este gráfico apresenta a distribuição de locuções verbais por documento. Como os textos são títulos, a maior parte tem poucas locuções verbais.




Quantidade de documentos por quantidade de verbos

O gráfico mostra a quantidade de verbos por documento. A concentração em poucos verbos confirma que os títulos descrevem uma ação principal, como “apura”, “deflagra”, “apoia” ou “inicia”.




Quantidade de documentos por quantidade de verbos e auxiliares

Este gráfico soma verbos principais e auxiliares. A distribuição é próxima à de verbos porque os títulos do corpus usam poucos auxiliares.




Quantidade de documentos por quantidade de substantivos

O gráfico mostra a quantidade de substantivos por documento. A média de 2,76 substantivos por documento é coerente com títulos que nomeiam objetos, ações, instituições e temas.




Quantidade de documentos por quantidade de auxiliares e substantivos

Este gráfico combina verbos auxiliares e substantivos. A distribuição acompanha principalmente os substantivos, pois auxiliares aparecem pouco no corpus.




Quantidade de documentos por quantidade de entidades reconhecidas

O gráfico mostra quantas entidades foram reconhecidas por documento. A mediana de 2 entidades por documento é adequada para títulos curtos que geralmente citam pelo menos uma instituição, localidade ou operação.



Distribuição do comprimento dos documentos tokenizados


Este gráfico apresenta o comprimento dos documentos após a tokenização. Ele confirma que a base está dentro do limite exigido, sem documentos longos.



Histograma do comprimento dos documentos tokenizados


O histograma reforça a concentração dos documentos em faixas baixas de tokens. Esse padrão é esperado porque a análise foi feita sobre títulos de notícias.

Distribuições por sentença




Quantidade de sentenças por quantidade de palavras

Este gráfico mostra a distribuição das sentenças por quantidade de palavras. A maior parte das sentenças tem tamanho curto ou intermediário, com média de 10,80 palavras.




Quantidade de sentenças por quantidade de tokens

O gráfico apresenta a quantidade de tokens BERT por sentença. A distribuição acompanha a de palavras, mas com valores um pouco maiores por causa da tokenização subword do BERT.




Quantidade de sentenças por quantidade de palavras sem stopwords

Este gráfico mostra a distribuição após remoção de stopwords. A redução do número de palavras evidencia a presença de termos funcionais comuns em português.




Quantidade de sentenças por quantidade de locuções verbais

O gráfico indica que as sentenças possuem poucas locuções verbais. Isso é compatível com títulos que tendem a ser sintaticamente enxutos.




Quantidade de sentenças por quantidade de verbos

Este gráfico mostra a quantidade de verbos por sentença. A concentração em um ou dois verbos confirma o caráter objetivo das sentenças analisadas.




Quantidade de sentenças por quantidade de verbos e auxiliares

O gráfico soma verbos e auxiliares por sentença. O comportamento permanece próximo ao gráfico de verbos, indicando baixa incidência de auxiliares.




Quantidade de sentenças por quantidade de substantivos

Este gráfico evidencia a distribuição de substantivos por sentença. A classe aparece com frequência relevante porque os títulos nomeiam temas, ações, instituições e objetos de notícia.



Quantidade de sentenças por quantidade de auxiliares e substantivos

O gráfico combina auxiliares e substantivos por sentença. Como há poucos auxiliares, o padrão observado é explicado majoritariamente pela presença de substantivos.



Quantidade de sentenças por quantidade de entidades

Este gráfico mostra a quantidade de entidades por sentença. A concentração em poucas entidades por sentença é esperada para títulos curtos, mas a presença recorrente de entidades confirma que o corpus é adequado para análise de NER.

Conferência dos requisitos

Requisito do enunciado	Situação no relatório
Escolher texto de dataset ou corpus com pelo menos 30 documentos	Atendido: dataset de notícias GovBR com 500 documentos processados.
<code>documentos.csv</code> com colunas <code>id</code> e <code>documento</code> separadas por <code>;</code>	Atendido: arquivo <code>data/documentos.csv</code> possui exatamente essas duas colunas.
<code>id</code> inteiro	Atendido: IDs inteiros únicos de 1 a 500.
<code>documento</code> string com uma ou mais sentenças	Atendido: não há documentos vazios; após segmentação foram geradas 567 sentenças.
Documento com até 512 tokens	Atendido: maior documento verificado com 42 tokens BERT incluindo tokens especiais; no notebook de análise, o máximo observado foi 40 tokens.
Executar <code>1_1</code> , <code>1_2</code> , <code>1_3</code> e <code>2_1</code>	Atendido: notebooks executados em ordem no <code>.venv</code> .
Descrição do texto utilizado	Atendido na seção “Descrição do texto utilizado”.
Exemplo de POS Tagging	Atendido na seção “Exemplo de POS Tagging”.
Exemplo de NER	Atendido na seção “Exemplo de NER”.
Gráficos e tabelas gerados pelos notebooks	Atendido: tabelas resumidas no relatório, export completo em <code>relatorio_ad1_export/2_1_AnaliseDados_v1.md</code> e 40 gráficos linkados.
Link do GitHub com repositório pessoal	Atendido: link informado no início do relatório.
Estrutura semelhante ao repositório SRI, sem pasta <code>SRI</code> interna	Atendido: notebooks na raiz e arquivos gerados na pasta <code>data/</code> .

Observações finais

A estrutura do repositório segue o formato solicitado: notebooks na raiz e a pasta `data/` com os arquivos gerados. Não há uma pasta `SRI` dentro do repositório.