

# Relatório AD1 - Fernando Paladini

## Avaliação a Distância 1 - Tópicos Especiais

**Aluno:** Fernando Paladini

### Repositório

Link do repositório pessoal no GitHub: <https://github.com/paladini/sri>

Pasta de saída com o relatório e artefatos gerados: [output/](#)

### Execução dos notebooks

Antes da execução dos Notebooks principais, foi criado e executado o notebook

`0_0_PrepararDocumentosCSV_trainjson_v1.ipynb`. Esse notebook adapta o dataset escolhido para o formato de entrada esperado pelos notebooks disponibilizados pelo professor, gerando o arquivo `data/documentos.csv` com as colunas `id` e `documento`.

Os notebooks disponibilizados pelo professor foram executados em 24/05/2026 na ordem solicitada:

1. `1_1_Segmentacao_Limpeza_v1.ipynb`
2. `1_2_GerarPOS_v1.ipynb`
3. `1_3_NER_spacy_v1.ipynb`
4. `2_1_AnaliseDados_v1.ipynb`

Os arquivos de dados gerados pelos notebooks ficam na pasta `data/`. Os relatórios, imagens e exports ficam centralizados na pasta [output/](#). Os principais arquivos adicionados ao repositório foram:

| Arquivo                                                             | Descrição                                                                                      |
|---------------------------------------------------------------------|------------------------------------------------------------------------------------------------|
| <code>0_0_PrepararDocumentosCSV_trainjson_v1.ipynb</code>           | Notebook criado para adaptar o dataset escolhido ao formato esperado pela sequência principal. |
| <code>data/dataset.csv</code>                                       | Documentos limpos e segmentados em sentenças.                                                  |
| <code>data/datasetpos.csv</code>                                    | Saída de POS Tagging gerada com spaCy.                                                         |
| <code>data/datasetner.csv</code>                                    | Saída de NER gerada com spaCy.                                                                 |
| <code>output/relatorio_ad1.md</code>                                | Relatório principal da Avaliação à Distância 1.                                                |
| <code>output/relatorio_ad1_export/2_1_AnaliseDados_v1.md</code>     | Export completo do notebook de análise com tabelas e gráficos.                                 |
| <code>output/relatorio_ad1_export/2_1_AnaliseDados_v1_files/</code> | Imagens PNG geradas pelo notebook de análise.                                                  |

Essa organização mantém a raiz do repositório semelhante ao SRI original, com notebooks na raiz e a pasta `data/` com os arquivos processados, enquanto os materiais finais de entrega ficam agrupados em

output/ .

## Descrição do texto utilizado

O corpus utilizado foi o dataset de notícias do GovBR disponível no Hugging Face: [divergente/noticias-govbr-ptbr-1](#).

Como os notebooks `1_1` até `2_1`, disponibilizados pelo professor, esperam um arquivo `data/documentos.csv` com as colunas `id` e `documento`, foi criado o notebook `0_0_PrepararDocumentosCSV_trainjson_v1.ipynb` para adaptar o dataset escolhido a esse formato. O script lê o arquivo de entrada do dataset (`train.json`), extrai o campo textual utilizado na análise, normaliza os registros e gera o CSV consumido pelas etapas seguintes.

Após a adaptação, o corpus utilizado no processamento ficou preparado no arquivo `data/documentos.csv`. Ele possui 500 documentos curtos, armazenados nas colunas `id` e `documento`. Cada documento corresponde a um título textual em português extraído de notícias do portal GovBR. A base utilizada contém principalmente títulos relacionados a governo, controle público, Polícia Federal, CGU, operações, investigações, Covid-19 e ações institucionais.

Depois do pré-processamento, o arquivo `data/dataset.csv` manteve 500 documentos e 567 sentenças. O processamento linguístico foi feito com spaCy, usando o modelo `pt_core_news_lg`; a análise também utiliza o tokenizador BERT `neuralmind/bert-base-portuguese-cased`.

Resumo geral da base:

| Métrica                         | Valor               |
|---------------------------------|---------------------|
| Documentos                      | 500                 |
| Sentenças                       | 567                 |
| Entidades nomeadas reconhecidas | 1032                |
| Classes NER encontradas         | LOC, MISC, ORG, PER |

## Exemplo de POS Tagging

Sentença utilizada:

Brasil inicia construção do 5 Plano de Ação Nacional de Governo Aberto

| Token      | POS   | Lema       |
|------------|-------|------------|
| Brasil     | PROPN | Brasil     |
| inicia     | VERB  | iniciar    |
| construção | NOUN  | construção |
| do         | ADP   | de o       |
| 5          | PROPN | 5          |
| Plano      | PROPN | Plano      |
| de         | ADP   | de         |
| Ação       | PROPN | Ação       |
| Nacional   | PROPN | Nacional   |
| de         | ADP   | de         |
| Governo    | PROPN | Governo    |
| Aberto     | PROPN | Aberto     |

Verbo identificado na sentença: `inicia` .

## Exemplo de NER

Sentença utilizada:

Brasil inicia construção do 5 Plano de Ação Nacional de Governo Aberto

| Entidade                                   | Classe | Início | Fim |
|--------------------------------------------|--------|--------|-----|
| Brasil                                     | LOC    | 0      | 6   |
| 5 Plano de Ação Nacional de Governo Aberto | MISC   | 28     | 70  |

# Tabelas da análise de dados

## Distribuição de POS no corpus

| POS   | Ocorrências |
|-------|-------------|
| PROPN | 1612        |
| NOUN  | 1382        |
| ADP   | 1353        |
| VERB  | 725         |
| ADJ   | 336         |
| NUM   | 178         |
| PUNCT | 136         |
| CCONJ | 132         |
| DET   | 112         |
| ADV   | 62          |
| SCONJ | 55          |
| AUX   | 19          |
| PRON  | 16          |
| SYM   | 5           |

## Distribuição de NER no corpus

| Classe | Ocorrências | Exemplo mais frequente |
|--------|-------------|------------------------|
| LOC    | 492         | Polícia Federal        |
| ORG    | 378         | PF                     |
| MISC   | 151         | BPFRON                 |
| PER    | 11          | LENI NCIA              |

## Estatísticas por documento

| Estatística   | Sentenças | Palavras | Tokens BERT | Palavras sem stopwords | Verbos | Substantivos | Entidades |
|---------------|-----------|----------|-------------|------------------------|--------|--------------|-----------|
| Média         | 1.13      | 12.25    | 17.19       | 8.52                   | 1.45   | 2.76         | 2.06      |
| Desvio padrão | 0.45      | 3.61     | 5.25        | 2.40                   | 0.71   | 1.40         | 0.90      |
| Mínimo        | 1.00      | 3.00     | 3.00        | 2.00                   | 0.00   | 0.00         | 0.00      |
| Mediana       | 1.00      | 12.00    | 17.00       | 8.00                   | 1.00   | 3.00         | 2.00      |
| Máximo        | 4.00      | 27.00    | 40.00       | 19.00                  | 4.00   | 7.00         | 6.00      |

## Estatísticas por sentença

| Estatística   | Palavras | Tokens BERT | Palavras sem stopwords | Verbos | Substantivos | Entidades |
|---------------|----------|-------------|------------------------|--------|--------------|-----------|
| Média         | 10.80    | 15.16       | 7.51                   | 1.28   | 2.44         | 1.82      |
| Desvio padrão | 4.53     | 6.28        | 2.96                   | 0.77   | 1.50         | 0.89      |
| Mínimo        | 1.00     | 1.00        | 0.00                   | 0.00   | 0.00         | 0.00      |
| Mediana       | 11.00    | 15.00       | 8.00                   | 1.00   | 2.00         | 2.00      |
| Máximo        | 23.00    | 38.00       | 17.00                  | 4.00   | 7.00         | 5.00      |

## Estatísticas por janela


| Estatística   | Palavras | Tokens BERT | Palavras janela 3 | Palavras janela 5 | Tokens janela 3 | Tokens janela 5 |
|---------------|----------|-------------|-------------------|-------------------|-----------------|-----------------|
| Média         | 10.80    | 15.16       | 12.36             | 12.52             | 17.41           | 17.64           |
| Desvio padrão | 4.53     | 6.28        | 3.92              | 3.83              | 5.72            | 5.60            |
| Mínimo        | 1.00     | 1.00        | 2.00              | 3.00              | 2.00            | 3.00            |
| Mediana       | 11.00    | 15.00       | 12.00             | 12.00             | 17.00           | 17.00           |
| Máximo        | 23.00    | 38.00       | 27.00             | 27.00             | 40.00           | 40.00           |

As tabelas completas exportadas diretamente do notebook estão em [relatorio\\_ad1\\_export/2\\_1\\_AnaliseDados\\_v1.md](#).

## Gráficos gerados pelo notebook de análise


Todos os gráficos abaixo foram gerados pelo notebook `2_1_AnaliseDados_v1.ipynb`, a partir dos arquivos `data/dataset.csv`, `data/datasetpos.csv` e `data/datasetner.csv`.

# Por documento




Boxplot das estatísticas gerais por documento

Este boxplot resume as medidas gerais por documento, como quantidade de sentenças, palavras, tokens BERT, palavras sem stopwords, verbos, substantivos e entidades. A maior parte dos documentos é curta, com mediana de 12 palavras, 17 tokens BERT e 1 sentença por documento.




Boxplot de POS Tagging por documento

O gráfico compara a distribuição das classes gramaticais por documento. As classes mais presentes são **PROPN** , **NOUN** e **ADP** , o que faz sentido para títulos de notícias, pois eles concentram nomes próprios, substantivos e preposições.




Distribuição de POS Tagging por documento

Este gráfico mostra a frequência total das classes POS no corpus. A predominância de **PROPN** , **NOUN** , **ADP** e **VERB** é coerente com um corpus formado por títulos jornalísticos institucionais.



### Boxplot de NER por documento

O boxplot de NER apresenta a quantidade de entidades por classe em cada documento. As classes **LOC** e **ORG** aparecem com mais frequência, resultado esperado para notícias do GovBR que citam órgãos, localidades, operações e instituições.




### Distribuição de NER por documento

Este gráfico sintetiza a distribuição das entidades nomeadas. A classe **LOC** foi a mais frequente, seguida de **ORG**, **MISC** e **PER**; isso mostra que o corpus contém mais referências geográficas e institucionais do




que nomes de pessoas.

Por sentença




Boxplot das estatísticas gerais por sentença

O gráfico apresenta as estatísticas no nível das sentenças. Como os documentos são títulos curtos, as sentenças também têm distribuição concentrada: média de 10,80 palavras e 15,16 tokens BERT por sentença.



### Boxplot de POS Tagging por sentença

Este boxplot mostra como as classes POS se distribuem por sentença. **PROPN**, **NOUN** e **ADP** continuam concentrando os maiores valores, confirmando o padrão observado na análise por documento.



### Distribuição de POS Tagging por sentença

O gráfico agrega as ocorrências de POS nas sentenças. Ele reforça que a estrutura linguística dos títulos é formada principalmente por nomes próprios, substantivos, preposições e verbos.




Gráfico POS por sentença - ADP

Este gráfico detalha a ocorrência de **ADP** por sentença. A frequência de preposições é compatível com títulos que conectam órgãos, ações, locais e complementos, como em expressões do tipo “de”, “em” e “para”.






Gráfico POS por sentença - PROPN

O gráfico de **PROPN** destaca a presença de nomes próprios nas sentenças. Esse resultado é esperado em notícias governamentais, que mencionam instituições, programas, operações e localidades específicas.



### Gráfico POS por sentença - NOUN

A distribuição de **NOUN** mostra a frequência de substantivos comuns. Essa classe é importante no corpus porque os títulos descrevem ações, objetos de investigação, políticas públicas e temas administrativos.



### Gráfico POS por sentença - VERB

O gráfico de **VERB** indica que a maioria das sentenças contém poucos verbos, geralmente um ou dois. Isso é coerente com títulos jornalísticos, que costumam expressar uma ação principal de forma direta.




Gráfico POS por sentença - ADJ

O gráfico de **ADJ** mostra menor frequência de adjetivos em comparação com substantivos e nomes próprios. O resultado combina com o estilo informativo dos títulos, que tende a priorizar fatos e entidades.






Gráfico POS por sentença - NUM

O gráfico de **NUM** evidencia ocorrências numéricas em parte das sentenças. Isso aparece em títulos com datas, valores, números de operações, planos, edições ou quantidades.



### Boxplot de NER por sentença

O boxplot de NER por sentença mostra que cada sentença normalmente possui poucas entidades, com mediana de 2 entidades. Isso é compatível com sentenças curtas oriundas de títulos.



### Distribuição de NER por sentença

Este gráfico mostra a frequência das classes NER nas sentenças. **LOC** e **ORG** seguem como as classes mais relevantes, indicando presença forte de lugares e organizações.




Gráfico NER por sentença - LOC

O gráfico de **LOC** detalha as entidades de localização por sentença. A concentração dessa classe é coerente com notícias que citam estados, cidades, países, órgãos tratados pelo modelo como localização e áreas de atuação.




Gráfico NER por sentença - ORG

O gráfico de **ORG** mostra a distribuição de organizações por sentença. A presença de órgãos como PF e CGU explica a frequência dessa classe no corpus.





Gráfico NER por sentença - MISC

O gráfico de **MISC** reúne entidades diversas que não se encaixam diretamente como pessoa, organização ou localização. Essa classe aparece em nomes de operações, programas e expressões institucionais.


## Distribuições por documento



Quantidade de documentos por quantidade de sentenças


Este gráfico confirma que a maioria dos documentos possui apenas uma sentença. Isso faz sentido porque o corpus processado utiliza títulos de notícias, que normalmente são textos curtos.






### Quantidade de documentos por quantidade de palavras

O gráfico mostra a distribuição dos documentos pela quantidade de palavras. A maior concentração fica em documentos curtos, com mediana de 12 palavras.




### Quantidade de documentos por quantidade de tokens

Este gráfico mostra a distribuição por tokens BERT. A mediana de 17 tokens e o máximo de 40 no dataset processado indicam que os documentos estão muito abaixo do limite de 512 tokens.




### Quantidade de documentos por quantidade de palavras sem stopwords

O gráfico mostra a quantidade de palavras restantes após a remoção de stopwords. A redução em relação ao total de palavras é esperada, pois títulos em português contêm preposições e artigos frequentes.




### Quantidade de documentos por quantidade de locuções verbais

Este gráfico apresenta a distribuição de locuções verbais por documento. Como os textos são títulos, a maior parte tem poucas locuções verbais.




Quantidade de documentos por quantidade de verbos

O gráfico mostra a quantidade de verbos por documento. A concentração em poucos verbos confirma que os títulos descrevem uma ação principal, como “apura”, “deflagra”, “apoia” ou “inicia”.




Quantidade de documentos por quantidade de verbos e auxiliares

Este gráfico soma verbos principais e auxiliares. A distribuição é próxima à de verbos porque os títulos do corpus usam poucos auxiliares.




### Quantidade de documentos por quantidade de substantivos

O gráfico mostra a quantidade de substantivos por documento. A média de 2,76 substantivos por documento é coerente com títulos que nomeiam objetos, ações, instituições e temas.




### Quantidade de documentos por quantidade de auxiliares e substantivos

Este gráfico combina verbos auxiliares e substantivos. A distribuição acompanha principalmente os substantivos, pois auxiliares aparecem pouco no corpus.




Quantidade de documentos por quantidade de entidades reconhecidas

O gráfico mostra quantas entidades foram reconhecidas por documento. A mediana de 2 entidades por documento é adequada para títulos curtos que geralmente citam pelo menos uma instituição, localidade ou operação.



Distribuição do comprimento dos documentos tokenizados


Este gráfico apresenta o comprimento dos documentos após a tokenização. Ele confirma que a base está dentro do limite exigido, sem documentos longos.



Histograma do comprimento dos documentos tokenizados


O histograma reforça a concentração dos documentos em faixas baixas de tokens. Esse padrão é esperado porque a análise foi feita sobre títulos de notícias.

## Distribuições por sentença




Quantidade de sentenças por quantidade de palavras

Este gráfico mostra a distribuição das sentenças por quantidade de palavras. A maior parte das sentenças tem tamanho curto ou intermediário, com média de 10,80 palavras.




### Quantidade de sentenças por quantidade de tokens

O gráfico apresenta a quantidade de tokens BERT por sentença. A distribuição acompanha a de palavras, mas com valores um pouco maiores por causa da tokenização subword do BERT.




### Quantidade de sentenças por quantidade de palavras sem stopwords

Este gráfico mostra a distribuição após remoção de stopwords. A redução do número de palavras evidencia a presença de termos funcionais comuns em português.



### Quantidade de sentenças por quantidade de locuções verbais


O gráfico indica que as sentenças possuem poucas locuções verbais. Isso é compatível com títulos que tendem a ser sintaticamente enxutos.



### Quantidade de sentenças por quantidade de verbos


Este gráfico mostra a quantidade de verbos por sentença. A concentração em um ou dois verbos confirma o caráter objetivo das sentenças analisadas.






### Quantidade de sentenças por quantidade de verbos e auxiliares

O gráfico soma verbos e auxiliares por sentença. O comportamento permanece próximo ao gráfico de verbos, indicando baixa incidência de auxiliares.




### Quantidade de sentenças por quantidade de substantivos

Este gráfico evidencia a distribuição de substantivos por sentença. A classe aparece com frequência relevante porque os títulos nomeiam temas, ações, instituições e objetos de notícia.



### Quantidade de sentenças por quantidade de auxiliares e substantivos

O gráfico combina auxiliares e substantivos por sentença. Como há poucos auxiliares, o padrão observado é explicado majoritariamente pela presença de substantivos.



### Quantidade de sentenças por quantidade de entidades

Este gráfico mostra a quantidade de entidades por sentença. A concentração em poucas entidades por sentença é esperada para títulos curtos, mas a presença recorrente de entidades confirma que o corpus é adequado para análise de NER.