

Avaliação a Distância 2

Projeção de Embeddings dos Notebooks

Tópicos Especiais em Computação: Semântica e Recuperação de Informação

Aluno: Fernando Paladini

Repositório pessoal: <https://github.com/paladini/sri>

Enunciado da AD2

Com o texto analisado na Avaliação a Distância 1, realizar a projeção de embeddings dos notebooks:

- [3_2_1_GerarArquivosProjecaoEmbeddingsDocumento_v1.ipynb](#)
- [3_2_2_GerarArquivosProjecaoEmbeddingsToken_v1.ipynb](#)
- [3_2_3_GerarArquivosProjecaoEmbeddingsToken_Documento_v1.ipynb](#)
- [3_2_4_GerarArquivosProjecaoEmbeddingsSentenca_Documento_v1.ipynb](#)

Os notebooks originais estão disponíveis em <https://github.com/osmarbraz/sri>.

Após realizar a execução dos notebooks, criar um documento PDF com printscreens das projeções de documento, tokens, tokens e documento, sentença e documento, identificando os itens projetados.

O documento também deve conter o link do repositório pessoal no GitHub, com notebooks na raiz e arquivos gerados na pasta projecao.

Dataset e execução

Foi reutilizado o texto analisado na Avaliação a Distância 1: o dataset de notícias GovBR divergente/noticias-govbr-ptbr-1, adaptado para data/documentos.csv com 500 documentos curtos em português. Esse corpus é diferente do CSTNews presente no exemplo original dos notebooks.

A consideração recebida na AD1 foi incorporada como limitação metodológica: documentos com mais de uma sentença oferecem mais contexto semântico. Nesta AD2, mantive o corpus da AD1 para cumprir a continuidade solicitada no enunciado.

Os quatro notebooks de projeção foram executados com BERTimbau (neuralmind/bert-base-portuguese-cased). Os arquivos de embeddings e metadados foram salvos na pasta projecao/.

Arquivos gerados

Projeção	Arquivo de registros	Metadados	Pontos
Documento	projecao/documento/records_documento_768_base_CLS.tsv	projecao/documento/meta_documento_768_base_CLS.tsv	500
Tokens	projecao/token/DOALL_records_token_768_base_POOL.tsv	projecao/token/DOALL_meta_token_768_base_POOL.tsv	6.123
Tokens e documento	projecao/token_documento/DOALL_records_token_documento_768_base_POOL.tsv	projecao/token_documento/DOALL_meta_token_documento_768_base_POOL.tsv	6.623
Sentença e documento	projecao/sentenca_documento/DOALL_records_sentenca_documento_768_base.tsv	projecao/sentenca_documento/DOALL_meta_sentenca_documento_768_base.tsv	1.067

Links do Embedding Projector

Documento: [abrir no Embedding Projector](#)

Tokens: [abrir no Embedding Projector](#)

Tokens e documento: [abrir no Embedding Projector](#)


Sentença e documento: [abrir no Embedding Projector](#)

Critério visual

Os prints abaixo foram capturados no TensorBoard Embedding Projector com PCA em duas dimensões. A busca por Brasil deixa visíveis os pontos selecionados, os rótulos e a lista de resultados, permitindo identificar o documento, o token e a sentença usados como referência.

Printscreen 1 - Projeção de documento


Documento projetado: Brasil inicia construção do 5 Plano de Ação Nacional de Governo Aberto



O painel mostra os 500 documentos do corpus GovBR projetados por PCA a partir dos embeddings BERTimbau. A busca por Brasil seleciona 14 documentos, destacados em vermelho e com rótulos visíveis. O documento de referência aparece próximo de outros títulos ligados a ações da CGU, Polícia Federal e governo federal, sugerindo agrupamento semântico por tema institucional.

Printscreen 2 - Projeção de tokens


Token projetado: Brasil - documento 1, índice 0.



O painel mostra 6.123 embeddings de tokens, com a projeção configurada em Color by: POS-Tag. A busca por Brasil destaca ocorrências do token e variações como Brasileiro, Brasileiras e brasileira. O token escolhido pertence ao documento 1 e aparece em uma região compartilhada por termos de mesma família lexical.

Printscreen 3 - Projeção de tokens e documento

Token e documento projetados: Brasil e documento 1.




O painel combina tokens e documentos no mesmo espaço vetorial, totalizando 6.623 pontos. A opção Color by: Granularidade diferencia os tipos de ponto, enquanto a busca por Brasil destaca tokens relacionados ao termo pesquisado. Essa visualização permite comparar a posição do token Brasil com documentos do corpus que tratam de assuntos próximos.

Printscreen 4 - Projeção de sentença e documento

Sentença projetada: Brasil inicia construção do 5 Plano de Ação Nacional de Governo Aberto

Documento projetado: Brasil inicia construção do 5 Plano de Ação Nacional de Governo Aberto



O painel combina sentenças e documentos em uma projeção com 1.067 pontos. A opção Color by: Granularidade separa sentenças e documentos, enquanto a busca por Brasil seleciona unidades textuais relacionadas ao termo. A sentença/documento de referência aparece junto de outros títulos governamentais, permitindo observar proximidade semântica entre níveis textuais diferentes.