

Avaliação a Distância 2

Projeção de Embeddings - Tópicos Especiais em Computação: Semântica e Recuperação de Informação

Aluno: Fernando Paladini

Repositório pessoal: <https://github.com/paladini/sri>

Dataset e execução

Foi reutilizado o texto analisado na Avaliação a Distância 1: o dataset de notícias GovBR divergente/noticias-govbr-ptbr-1, adaptado para 500 títulos em português em data/documentos.csv. Esse corpus é diferente do CSTNews presente no exemplo original dos notebooks.

Os quatro notebooks de projeção solicitados foram executados localmente com BERTimbau (neuralmind/bert-base-portuguese-cased). As células específicas de Colab, instalação interativa e TensorBoard foram neutralizadas para permitir execução reprodutível no ambiente local.

Arquivos gerados

Projeção	Arquivo de registros	Pontos
Documento	projecao/documento/records_documento_768_base_CLS.tsv	500
Tokens	projecao/token/DOALL_records_token_768_base_POOL.tsv	6.123
Tokens e documento	projecao/token_documento/DOALL_records_token_documento_768_base_POOL.tsv	6.623
Sentença e documento	projecao/sentenca_documento/DOALL_records_sentenca_documento_768_base.tsv	1.067

Links do Embedding Projector

Documento: https://projector.tensorflow.org/?config=https://raw.githubusercontent.com/paladini/sri/main/projecao/config_documento.json

Tokens:

https://projector.tensorflow.org/?config=https://raw.githubusercontent.com/paladini/sri/main/projecao/config_token.json

Tokens e documento: https://projector.tensorflow.org/?config=https://raw.githubusercontent.com/paladini/sri/main/projecao/config_token_documento.json

Sentença e documento: https://projector.tensorflow.org/?config=https://raw.githubusercontent.com/paladini/sri/main/projecao/config_sentenca_documento.json

Leitura das projeções

As projeções foram reduzidas para duas dimensões com PCA apenas para visualização, então elas não mostram toda a informação dos embeddings originais de 768 dimensões. Mesmo assim, os gráficos ajudam a observar a distribuição dos documentos, tokens e sentenças do corpus GovBR. Em todos os casos eu destaquei o mesmo documento de referência, usando o token Brasil e a primeira sentença/documento, para facilitar a comparação entre as quatro projeções pedidas.

Gráfico de projeção de documento

Documento projetado: Brasil inicia construção do 5 Plano de Ação Nacional de Governo Aberto




Gráfico de projeção de tokens

Token projetado: Brasil - documento 1, índice 0.




Gráfico de projeção de tokens e documento

Token e documento projetados: Brasil e documento 1.




Gráfico de projeção de sentença e documento

Sentença projetada: Brasil inicia construção do 5 Plano de Ação Nacional de Governo Aberto

Documento projetado: Brasil inicia construção do 5 Plano de Ação Nacional de Governo Aberto

